

Nathan Leclercq

Data Engineer - MLOps

✉ nathan.leclercq9@protonmail.com | 🏠 nathan.leclercq.spacesheep.ovh | 📷 nathanlq | 🌐 nathan-leclercq

Profil

Data Engineer & MLOps chez DataKhi depuis 3 ans (alternance puis CDI depuis sept. 2025). Je conçois et opère des plateformes data de bout en bout — collecte, pipelines ETL, entrepôt, déploiement, monitoring — et couvre le cycle ML complet : préparation des données, feature engineering, conception et entraînement de modèles, puis mise en production. À l'aise autant sur stacks **open source** que je déploie et opère moi-même (PostgreSQL, Airflow, Kubernetes, Ansible) que sur cloud managé (Microsoft Fabric, Azure). Formation initiale en mathématiques, Master Machine Learning (Lille).

Expérience

Mission Nyukom — plateforme data télécom

DataKhi · CDI · Data Engineer

oct. 2025 – présent

- Plateforme data télécom de bout en bout pour le pilotage multi-client : de la collecte terrain (3CX, API Centreon) aux rapports Power BI, via un data lake objet et un entrepôt **PostgreSQL** en schéma étoile
- Infrastructure déployée et opérée en autonomie sur **Kubernetes** (K3s), orchestrée par **Apache Airflow** et provisionnée en **Ansible** : pipelines idempotents, partitionnés, backfill historique et reprise sur erreur
- Migration du stockage objet **MinIO** vers **Garage** pour fiabiliser les workloads sensibles, sans interruption de service (mirror J-1 maintenu pendant la recette)

Référentiel d'entreprises & moteur de prospection B2B

DataKhi · CDI · Data Engineer

2025 – présent

- Référentiel national d'entreprises pour les équipes commerciales : pipeline **ETL** alimentant un entrepôt **PostgreSQL** de près de 15M entreprises et 23M établissements (INSEE), enrichi de ratios financiers (BCE/INPI) et de données dirigeants via API publiques
- Ingestion robuste jouable : modes full (swap atomique préservant les enrichissements) et incrémental (UPSERT), tolérante aux erreurs, déployée en **CronJob Kubernetes**
- Chaîne de prospection automatisée par-dessus le référentiel : ciblage des prospects, résolution des sites web, recherche de contacts vérifiés et rédaction d'emails personnalisés par **LLM** (Mistral)

Benchmark stockage objet (Garage vs MinIO)

DataKhi · CDI · Data / Platform Engineer

2025 – 2026

- Benchmark **Garage vs MinIO** (cluster multi-nœuds) pour arbitrer le choix du stockage objet : débit de lecture **DuckDB**, écritures S3, résilience (coupure de nœud + recovery)
- Banc d'essai reproductible et automatisé (Docker Compose multi-nœuds + scripts de déploiement) — socle technique du talk **DevLille 2026**

Infrastructure data Hall U Need

DataKhi · CDI · Data Engineer

2023 – présent

- Run et évolution d'une plateforme data en production pour une entreprise de restauration : **Microsoft Fabric** (entrepôt + notebooks), **Azure Data Factory** (orchestration), pipelines de scraping custom Playwright pour les sources hors Azure
- Quotidien : gestion des incidents, maîtrise des coûts cloud, intégration de nouvelles sources métier (caisses, réservations, météo, RH, événementiel)

Prédiction d'affluence Hall U Need

DataKhi · CDI · ML Engineer

2023 – présent

- Industrialisation d'un système de prévision d'affluence (28 modèles **XGBoost** en régression quantile) pour dimensionner staffing et stocks : feature engineering riche (météo, calendrier, jours fériés, réservations), loss Huber custom, calibration des intervalles de confiance
- Mise en production dans **Microsoft Fabric** : pipeline **Azure Data Factory** orchestrant collecte → entraînement périodique → prédiction quotidienne (horizon 90 jours), modèles versionnés (date + MAE) sur OneLake
- Fiabilisation pérenne : contrôles qualité des données avec alerte email en cas d'anomalie, tests de non-régression (Pearson $\geq 0,999$), suivi des erreurs (MAE, couverture d'intervalle) et analyse rétrospective prédictions vs réel

Mission Tossée — agrégateur de mode éco-responsable

DataKhi · Alternance · Data / MLOps Engineer

2023 – 2025

- Écosystème data complet pour un agrégateur de mode éco-responsable : chaîne batch collecte → normalisation → enrichissement ML → API, sur un catalogue de 67 marques
- Note d'impact environnemental produit (24 indicateurs PEF via l'API **Ecobalyse**) : mapping matières, mise en cache et déduplication par fiabilité pour limiter les appels
- Collecte à grande échelle (Scrapy, Playwright, moteur de règles YAML maison) et entrepôt **PostgreSQL/pgvector** pour la recherche sémantique, exposé via une API **FastAPI**
- Pipelines déployés en workers **Kubernetes** (K3s) orchestrés par file de messages, déploiement hybride on-premise / Azure

Versioning Power BI — mission interne

DataKhi · Stage · Développeur FullStack

2023

- Système de versioning pour Power BI : backend C++ (différentiels de rapports), frontend React, distribution Electron

Compétences techniques

Data Engineering	PostgreSQL · SQL · Apache Airflow · Spark · pipelines ETL/ELT · schéma étoile · partitionnement · idempotence/backfill · PyArrow/Parquet · DuckDB · Microsoft Fabric · Azure Data Factory
Infra & Stockage	Linux/Bash · Kubernetes (K3s) · Docker · Ansible & Terraform (IaC, vault) · MinIO/Garage (S3) · Prometheus/Grafana/Loki · CI/CD (Forgejo, GitLab) · Azure
Langages	Python (Pandas, PyArrow, FastAPI) · SQL · Bash · Julia · notions Go, Rust
ML / MLOps	XGBoost · feature engineering · pgvector/embeddings · RAG (MCP, Ollama) · MLflow · CamemBERT
Langues	Français natif · Anglais professionnel (TOEIC 885)

Formation

2023 – 2025	Master Machine Learning , Université de Lille	Lille
2020 – 2023	Licence Informatique , Université de Lille	Lille
2017 – 2020	Cursus Mathématiques (L1–L3) , Université de Lille	Lille

Conférences & publications

Conférencier — DevLille 2026 : « Reprenez le contrôle de votre plateforme data face aux géants américains » — déploiement d'une plateforme data en cloud privé (MinIO/Garage, PostgreSQL, DuckDB, K3s).

Veille active — participant à plusieurs conférences tech : Cloud Nord 2024 et DevLille 2025.

Blog — 8 articles techniques sur datakhi.fr (plateforme data souveraine, stockage objet, migration open source, Airflow → Kestra, ML) + nathan.leclercq.spacesheep.ovh (séries Homelab, Book Reco).